
Creating Visual Cognitive Illusions

Abstract

已有研究将图像错觉建模为从输入到感知结果的映射过程，为系统性模拟与分析不同类型的视觉错觉提供了统一的理论框架。本文在该视角下进一步探讨该框架的表达边界，并在输入形式与应用场景两个层面进行扩展，以验证其泛化潜力与可控性。

1 Introduction

1.1 Problem Setting

Diffusion Illusion 所试图解决的核心问题已在原论文中进行了系统阐述，本文不再重复。通过对原方法的复现与提示词变体实验，我们观察到该框架在控制精度与错觉形式覆盖范围方面仍存在明显局限，进而引出以下扩展动机。

Image-based Supervision 文本到图像生成过程本身具有显著的语义歧义性与不确定性，使得仅依赖文本提示难以精确约束衍生图像的目标结构与语义。为此，本文引入图像作为监督信号，对衍生结果施加显式约束，从而提升生成结果的稳定性与可控性。该设定亦为后续诸如信息隐藏（如二维码嵌入）等应用提供了必要条件。

Hybrid / Distance Illusions 尽管原论文讨论了 Hybrid Illusion 与 Distance Illusion 等经典错觉形式，但其方法框架并未显式支持此类现象的生成。本文尝试将该类错觉统一表述为“基图—变换—衍生图像”的过程，并将其纳入 Diffusion Illusion 的整体建模范式，以实现更广泛的错觉类型覆盖。

Flexible Spatial Decomposition 原方法仅考虑规则正方形区域的分割与变换，并要求生成结果保持整体几何规整性。本文进一步放宽这一假设，允许采用非规则空间分割方式，同时不强制衍生图像保持正方形结构，从而扩展框架对复杂空间变换的适应能力。

Generalized Rotational Transformations 在旋转错觉方面，原论文仅涉及四次 90° 的基础旋转。本文将该操作推广至连续角度空间，使模型能够支持任意旋转角度下的错觉生成，从而增强其表达连续视觉变化的能力。

1.2 Related Work

Image Labels 相关研究主要探索如何利用 CLIP 等视觉-语言模型建立图像间的语义对齐，实现更精确的图像到图像生成。主流工作聚焦于开发图像引导的生成方法，通过图像特征约束确保生成内容与参考图像在语义层面保持一致。

Hybrid Illustration 该领域主要研究多尺度图像生成与频域分离技术。核心思路是利用高斯模糊和频域变换模拟不同观察距离下的视觉感知差异，使得单一图像在不同尺度下呈现截然不同的语义内容。

Flexible image shapes 相关研究集中在可变形图像表示和非规则网格生成。主流方法通过可学习的掩码机制和自适应坐标映射，实现任意形状的图像分割与重组，突破传统规则网格的限制。

Kaleidoscope effect 这属于旋转对称性生成研究范畴。相关论文主要探索如何将几何变换（特别是旋转、反射等对称操作）与生成模型结合，创造具有数学规律的美学图案。

2 Methods

2.1 Data

该方法为 zero-shot 方法，只需要冻结模型和 text 提示词可以进行训练，因此不需要大规模数据集，对于冻结模型，这里引用了几个已知的模型：

- **Stable Diffusion v1-4**: 作为基础扩散模型，使用预训练的 UNet、VAE 和 CLIP 文本编码器
- **CLIP (ViT-B/32)**: 用于图像-文本对齐和图像-图像相似性计算
- **DINO (ViT-B/16)**: 用于特征图提取和注意力引导（可选）

2.2 CLIP and Image Label

我们为了引入图片作为标签时，需要一个指标衡量两张图像在语义层面的相似程度，这里选择的指标为 CLIP (Contrastive Language-Image Pretraining)。

2.2.1 CLIP 图像特征提取

在我们的实现中，我们扩展了 CLIP 的功能，使其不仅能计算图像-文本相似度，还能提取图像的语义特征向量用于图像-图像相似性度量。

2.2.2 图像-图像相似性损失

在原本仅依赖文本条件 (text-to-image) 的训练损失之外, 我们额外引入一个基于 CLIP 的图像-图像相似性损失, 用来约束”参考图像”与”生成图像”在 CLIP 语义空间中保持一致:

$$\mathcal{L}_{\text{CLIP-image}} = 1 - \frac{\phi(I_{\text{gen}}) \cdot \phi(I_{\text{ref}})}{\|\phi(I_{\text{gen}})\| \|\phi(I_{\text{ref}})\|} \quad (1)$$

其中 $\phi(\cdot)$ 表示 CLIP 图像编码器, I_{gen} 为生成图像, I_{ref} 为参考图像。

在训练时, 我们计算总损失为:

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{SDS}} + \lambda_{\text{clip}} \cdot \mathcal{L}_{\text{CLIP-image}} \quad (2)$$

其中 $\mathcal{L}_{\text{SDS}}$ 为 Score Distillation Sampling 损失, λ_{clip} 为 CLIP 损失权重 (通常设为 0.05-0.2)。

2.3 Distance and Gaussian Blur

对于距离产生的视错觉, 我们利用频域变换的方法, 将其建模为一种高斯模糊变换, 距离越远意味着模糊越剧烈, 从而将视觉距离信息引入模型训练。

2.3.1 多尺度视图构建

我们定义基于视觉距离的可微分变换 T_d , 其中 d 表示观察距离:

- **近景视图** (T_{near}): 恒等变换 x 或轻微高通滤波, 保留高频纹理细节
- **远景视图** (T_{far}): 组合变换 $\text{Downsample}(\text{GaussianBlur}(x, \sigma_d))$, 其中 σ_d 与距离 d 成正比

变换的数学表达为:

$$T_{\text{near}}(x) = x \quad (3)$$

$$T_{\text{far}}(x) = \text{Downsample}_k(\mathcal{G}_{\sigma_d}(x)) \quad (4)$$

其中 $\mathcal{G}_{\sigma}$ 表示标准差为 σ 的高斯模糊, Downsample_k 表示 k 倍下采样。

2.3.2 频域分离引导

在优化循环中, 我们同时采样两个视图并计算 SDS 梯度:

$$T_{\text{near}}(x) \rightarrow \text{引导向 Prompt A (如精细线条、素描)} \quad (5)$$

$$T_{\text{far}}(x) \rightarrow \text{引导向 Prompt B (如色块、模糊轮廓)} \quad (6)$$

通过调节高斯核 σ 和损失权重, 迫使单一图像在不同频段承载截然不同的语义信息。

2.3.3 理论依据

该方法基于人眼视觉系统的两个特性：

1. **空间频率敏感性**: 近距离观察时, 人眼对高频细节敏感; 远距离时, 主要感知低频信息
2. **尺度不变性**: 在不同观察尺度下, 同一物体可能被识别为不同语义概念

通过高斯模糊的强度参数 σ , 我们可以精确控制模拟的观察距离:

$$\sigma(d) = \sigma_0 \cdot \frac{d}{d_0} \quad (7)$$

其中 d 为观察距离, d_0 为参考距离, σ_0 为基准模糊强度。

2.4 Simulate Overlap

为了模拟透光片的效果, 我们使用类似深度渲染中的重叠模拟。该方法通过乘性叠加与非线性映射, 模拟两层透明胶片叠放时的光学混合效果。具体算法如算法3所示。

算法3模拟了物理世界中的透光叠加过程: 底层图像与顶层图像分别代表两张胶片, 其像素值对应于透光率。算法通过指数运算 γ 模拟胶片的非线性响应 (伽马校正), 通过乘法运算模拟光穿过两层胶片后的衰减, 并通过亮度系数调整整体明暗。双曲正切函数 $\tanh$ 确保了输出值的稳定性和可微分性, 便于后续的梯度优化。

该函数支持两种模式:

纯净模式 ($CLEANMODE = \text{True}$): 使用固定参数, 产生稳定、一致的叠加效果, 适用于训练阶段。

随机模式 ($CLEANMODE = \text{False}$): 引入随机扰动 (指数 γ 、亮度 $brightness$ 、基底黑度 $black$), 模拟真实印刷中可能出现的色彩偏差、褪色或不均匀曝光, 从而增强生成结果的鲁棒性和自然感。

2.5 Flexible image shapes

该方法使用七巧板几何变换来构建图像对之间的对应关系。通过定义一组七巧板多边形的标准排列 (A 视图) 和目标排列 (B 视图), 生成两个 UV 映射 UV_A 和 UV_B , 将同一纹理图像 $\mathbf{T}$ 映射到不同排列的七巧板形状中。核心操作是通过可微的仿射变换和三角形光栅化, 将纹理坐标从源多边形映射到目标多边形。

训练时, 优化纹理参数 θ 使得同一纹理 $\mathbf{T}_\theta$ 通过 UV_A 和 UV_B 生成的图像 $\mathbf{I}_A$ 和 $\mathbf{I}_B$ 分别满足提示词 prompt_A 和 prompt_B 的语义约束。损失函数为:

$$\mathcal{L} = \sum_{i \in \{A, B\}} w_i \cdot \mathcal{L}_{\text{SDS}}(\text{clip}(\mathbf{I}_i), \text{prompt}_i)$$

其中 $\mathcal{L}_{\text{SDS}}$ 为 Score Distillation 损失, w_i 为权重系数。




图 1: Kaleidoscope effect under continuous rotational transformations.




图 2: Shape reassembly based on tangram.

3 Experiment Result

Hybrid Illustration 我们基于远近距离的模糊生成了结果，最后得到结果如图 3所示。

Kaleidoscope effect 我们对 $[0, 60, 120, 180, 240, 300]$ 这组角度进行了测试，提示词给定为 $['miku', 'froggo', 'lipstick', 'pyramids', 'burger', 'dinosaur']$ ，最后得到结果如图 1所示

Flexible image shapes 我们基于七巧板的形状重组图片，最后得到如图 2所示

4 Conclusion

本文在 Diffusion Illusion 框架基础上进行了多方面的扩展与创新，通过引入图像标签约束、距离感知的频域变换、灵活形状分割以及任意角度旋转的万花筒效果，验证了基于映射理论的视错觉生成框架具有较强的可扩展性和应用潜力。

4.1 可行性分析

本研究提出的扩展方案在实践中表现出良好的可行性：




图 3:

1. **图像标签引导的可行性**: 通过引入 CLIP 图像-图像相似性损失, 我们成功实现了参考图像对生成过程的精确约束。实验表明, 当 λ_{clip} 设置在 0.05-0.2 范围内时, 模型能够在遵循文本提示的同时, 有效保持与参考图像的语义一致性。这一特性为诸如“在风景画中隐藏二维码”等应用场景提供了技术基础。
2. **频域分离的物理可实现性**: 基于高斯模糊的多尺度视图构建方法, 成功模拟了观察距离变化产生的视错觉效应。通过调节 σ_d 参数, 我们能够控制“近景-远景”视图之间的平滑过渡, 证明了频域分离理论在扩散模型框架下的适用性。
3. **任意角度旋转的稳定性**: 扩展的旋转变换算法支持任意角度 (包括非 90 度整数倍) 的精确旋转, 同时保持了梯度的可微性和数值稳定性。六重对称 (60° 间隔) 和八重对称 (45° 间隔) 的万花筒效果均能稳定生成, 验证了旋转操作在视错觉生成中的普适性。

4.2 局限性分析

尽管取得了上述进展, 本研究仍存在一些局限性。包括: 计算效率问题: 引入 CLIP 图像编码和多尺度变换显著增加了计算开销; 语义一致性的平衡: 当参考图像与文本提示的语义差距较大时, 模型难以同时满足两者要求, 可能导致生成质量下降; 物理模拟的

简化：透光片重叠模拟忽略了实际物理过程中的诸多复杂因素，如折射、散射、多层介质干涉等效应。

4.3 未来工作展望

基于本研究的成果与局限，未来工作可从以下几个方向展开：多模态融合增强（将语音、3D 模型等更多模态信息纳入框架，拓展视错觉的创作维度）；信息隐藏与加密（将二维码隐藏在普通图像中，仅通过特定变换才能识别）；理论深化（研究生成模型的潜在空间结构与人类视觉感知的对应关系）。

References

- [1] Alexander, J.A. & Mozer, M.C. (1995) Template-based algorithms for connectionist rule extraction. In G. Tesauro, D.S. Touretzky and T.K. Leen (eds.), *Advances in Neural Information Processing Systems 7*, pp. 609–616. Cambridge, MA: MIT Press.
- [2] Bower, J.M. & Beeman, D. (1995) *The Book of GENESIS: Exploring Realistic Neural Models with the GEneral NEural SIEmulation System*. New York: TELOS/Springer-Verlag.
- [3] Hasselmo, M.E., Schnell, E. & Barkai, E. (1995) Dynamics of learning and recall at excitatory recurrent synapses and cholinergic modulation in rat hippocampal region CA3. *Journal of Neuroscience* **15**(7):5249-5262.

A Appendix / supplemental material

Algorithm 1 Diffusion Model Training with CLIP Constraint

Require: Text embedding $\mathbf{E}_t$, generated image $\mathbf{I}_{\text{gen}}$, reference image $\mathbf{I}_{\text{ref}}$, CLIP weight

λ_{clip}

Ensure: Total loss $\mathcal{L}_{\text{total}}$

- 1: ▷ Extract CLIP features
 - 2: $\mathbf{f}_{\text{gen}} \leftarrow \phi_{\text{CLIP}}(\mathbf{I}_{\text{gen}})$
 - 3: $\mathbf{f}_{\text{ref}} \leftarrow \phi_{\text{CLIP}}(\mathbf{I}_{\text{ref}})$
 - 4: ▷ Compute cosine similarity
 - 5: $\mathbf{f}_{\text{gen}}^{\text{norm}} \leftarrow \mathbf{f}_{\text{gen}} / \|\mathbf{f}_{\text{gen}}\|_2$
 - 6: $\mathbf{f}_{\text{ref}}^{\text{norm}} \leftarrow \mathbf{f}_{\text{ref}} / \|\mathbf{f}_{\text{ref}}\|_2$
 - 7: $s \leftarrow \langle \mathbf{f}_{\text{gen}}^{\text{norm}}, \mathbf{f}_{\text{ref}}^{\text{norm}} \rangle$
 - 8: ▷ CLIP loss
 - 9: $\mathcal{L}_{\text{clip}} \leftarrow 1 - s$
 - 10: ▷ Combine with diffusion loss
 - 11: $\mathcal{L}_{\text{sds}} \leftarrow \text{SDSLoss}(\mathbf{E}_t, \mathbf{I}_{\text{gen}})$
 - 12: $\mathcal{L}_{\text{total}} \leftarrow \mathcal{L}_{\text{sds}} + \lambda_{\text{clip}} \cdot \mathcal{L}_{\text{clip}}$
 - return** $\mathcal{L}_{\text{total}}$
-

Algorithm 2 Multi-scale Frequency-based Illusion Generation

Require: Base image $\mathbf{I}$, near-view prompt P_{near} , far-view prompt P_{far} , blur scale σ ,
downsampling factor k

Ensure: Final illusion image $\mathbf{I}_{\text{final}}$

```
1: Initialize diffusion model  $\mathcal{M}$ 
2: Initialize frequency transform parameters  $(\sigma, k)$ 
3: function NEARVIEW( $\mathbf{I}$ ) return  $\mathbf{I}$ 
4: end function
5: function FARVIEW( $\mathbf{I}$ )
6:    $\mathbf{I}_{\text{blur}} \leftarrow \text{GaussianBlur}(\mathbf{I}, \sigma)$ 
7:    $\mathbf{I}_{\text{down}} \leftarrow \text{Downsample}(\mathbf{I}_{\text{blur}}, k)$ 
8:    $\mathbf{I}_{\text{up}} \leftarrow \text{Upsample}(\mathbf{I}_{\text{down}})$  return  $\mathbf{I}_{\text{up}}$ 
9: end function
10: for  $i \leftarrow 1$  to  $N$  do
11:    $\mathbf{I}_{\text{base}} \leftarrow \text{LearnableImage}()$ 
12:    $\mathbf{I}_{\text{near}} \leftarrow \text{NearView}(\mathbf{I}_{\text{base}})$ 
13:    $\mathbf{I}_{\text{far}} \leftarrow \text{FarView}(\mathbf{I}_{\text{base}})$ 
14:    $\mathcal{L}_{\text{near}} \leftarrow \mathcal{M}.\text{Train}(P_{\text{near}}, \mathbf{I}_{\text{near}})$ 
15:    $\mathcal{L}_{\text{far}} \leftarrow \mathcal{M}.\text{Train}(P_{\text{far}}, \mathbf{I}_{\text{far}})$ 
16:   Optimize  $\mathcal{L}_{\text{near}} + \mathcal{L}_{\text{far}}$ 
17: end for
18:  $\mathbf{I}_{\text{final}} \leftarrow \text{GetFinalImage}()$  return  $\mathbf{I}_{\text{final}}$ 
```

Algorithm 3 Simulation of Transparent Overlay Effect

Require: Bottom image $\mathbf{B}$, top image $\mathbf{T}$

Ensure: Output image $\mathbf{O}$

```
1: Initialize CLEAN_MODE  $\leftarrow$  True, brightness  $b \leftarrow 3$ 
2: if CLEAN_MODE then
3:    $\gamma \leftarrow 1$ , black  $\leftarrow 0$ 
4: else
5:   Sample  $\gamma \sim \mathcal{U}(0.5, 1)$ 
6:   Sample  $b \sim \mathcal{U}(1, 5)$ 
7:   Sample black  $\sim \mathcal{U}(0, 0.5)$ 
8:   Mix  $\mathbf{B}$  and  $\mathbf{T}$  with black
9: end if
10:  $\mathbf{O} \leftarrow (\mathbf{B}^\gamma \odot \mathbf{T}^\gamma) \cdot b$ 
11:  $\mathbf{O} \leftarrow \text{Clamp}(\mathbf{O}, 0, 99)$ 
12:  $\mathbf{O} \leftarrow \tanh(\mathbf{O})$ 
    return  $\mathbf{O}$ 
```
